FIAP Aula Encerramento & REVISÃO GERAL

Redes Neurais, Deep Learning & Algoritmos Genéticos

Consolidação de conceitos: da modelagem do neurônio artificial às arquiteturas avançadas de IA e otimização bio-inspirada.

Prof. Mateus Dalbone

Roteiro da Aula

Grandes Eixos do Conhecimento



1. Fundamentos & Perceptron

Arquitetura do Neurônio, Funções de Ativação e Aprendizado Supervisionado.



2. Redes Multicamadas & Otimização

MLP, Algoritmo de Backpropagation e Otimizadores como Adam/SGD.



3. Deep Learning Espacial e Sequencial

CNNs para Visão Computacional e RNNs/LSTMs para Sequências Temporais.



4. Computação evolutiva

Otimização Estocástica, Seleção, Crossover e Mutação Genética.

Bloco 01 — Fundamentos

A Matemática do Neurônio Artificial

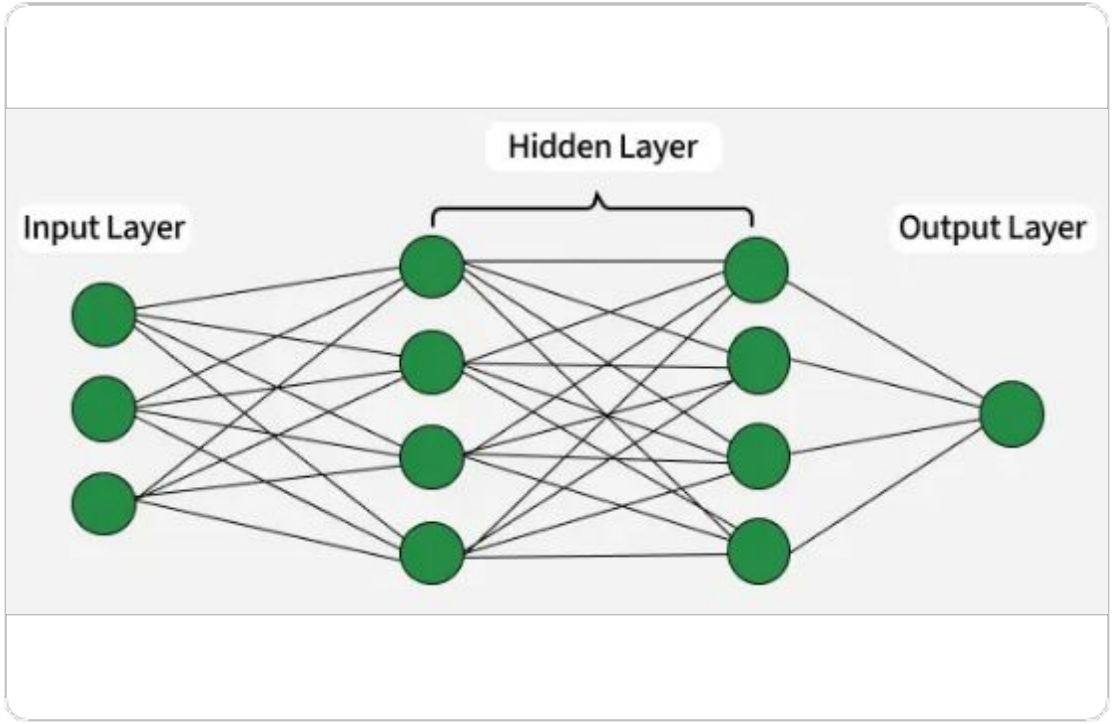
$$y = f\left(\sum_{i=1}^{n} w_i x_i + b\right)$$

Entradas ( ): Atributos e características dos dados.

Pesos ( ): Parâmetros treináveis de importância.

Vieses ( ): Deslocamento do ponto de ativação.

Função : Introduz não-linearidade no modelo.



Não-Linearidade

Principais Funções de Ativação

Sigmoide / Logística

Comprime saídas entre 0 e 1.

`Probabilidade Binária`

ReLU (Rectified Linear)

Retorna max(0, x). Mapeamento rápido.

`Padrão em Camadas Ocultas`

Softmax

Normaliza vetor em distribuições.

`Classificação Multiclasse`

Bloco 02 — Aprendizado

Ciclo do Algoritmo de Backpropagation

PASSO 01

Forward Pass

Propagação dos dados de entrada até a previsão final.

PASSO 02

Cálculo da Perda

Medição do erro via Loss Function (MSE ou Cross-Entropy).

PASSO 03

Backward Pass

Cálculo de gradientes via Regra da Cadeia em sentido inverso.

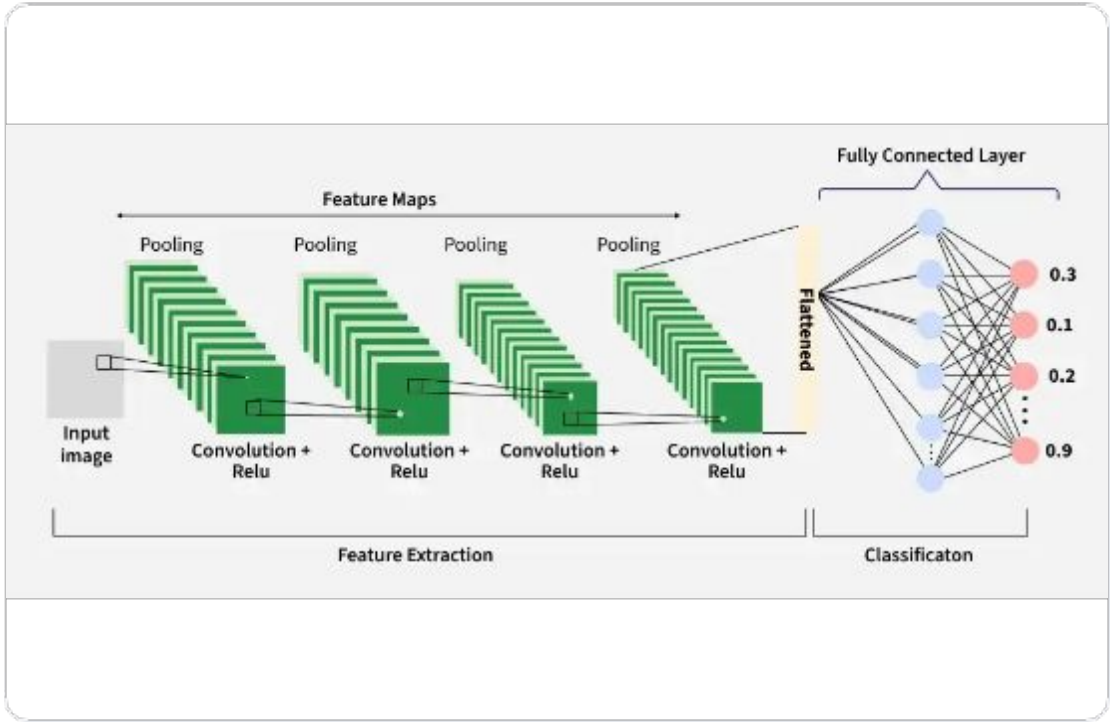
PASSO 04

Atualização

Otimizadores ajustam os pesos para minimizar o erro acumulado.

Bloco 03 — Deep Learning Espacial

Redes Convolucionais (CNNs)



Camadas Convolucionais: Aplicação de filtros para extração automática de bordas e texturas.

Pooling (Max/Average): Redução da dimensionalidade espacial e invariância a rotações.

Camadas Fully Connected: Classificação final a partir das mapas de atributos extraídos.

Aplicações Principais: Visão computacional, detecção de objetos e médica.

Bloco 03 — Processamento Sequencial

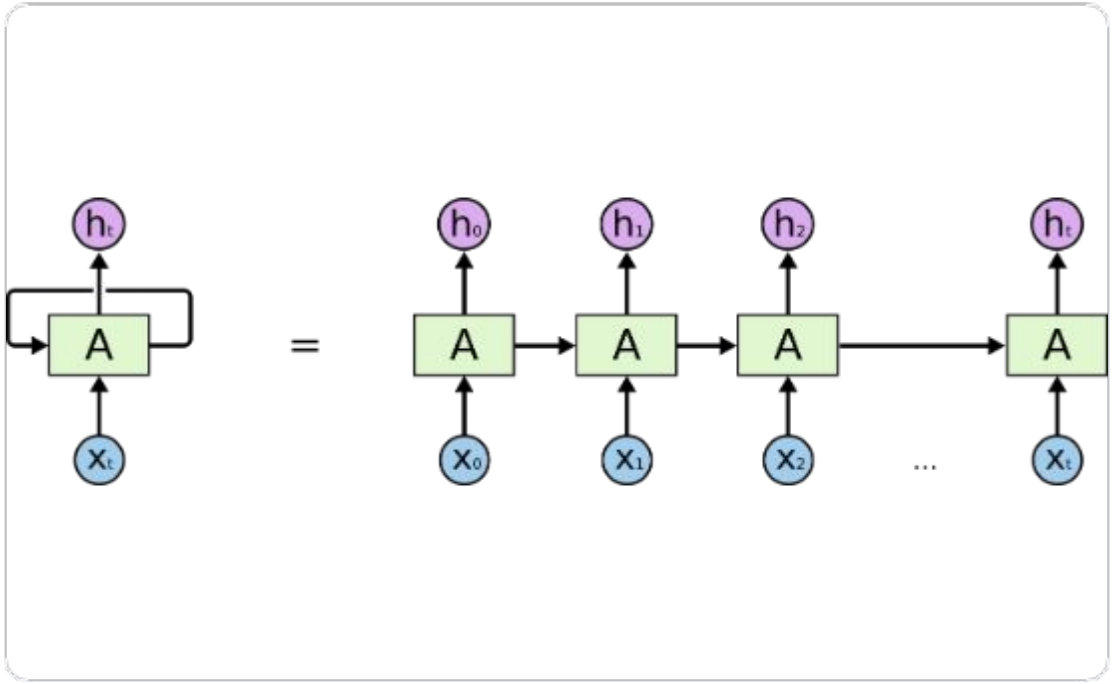
RNNs e Arquiteturas LSTM

O Desafio da Memória Curta

RNNs tradicionais sofrem com o problema do **Gradiente Desvanecente (Vanishing Gradient)** em sequências longas.

A Solução LSTM (Long Short-Term Memory)

Uso de portas internas (Forget, Input e Output Gates) para manter estados de memória de longo prazo.

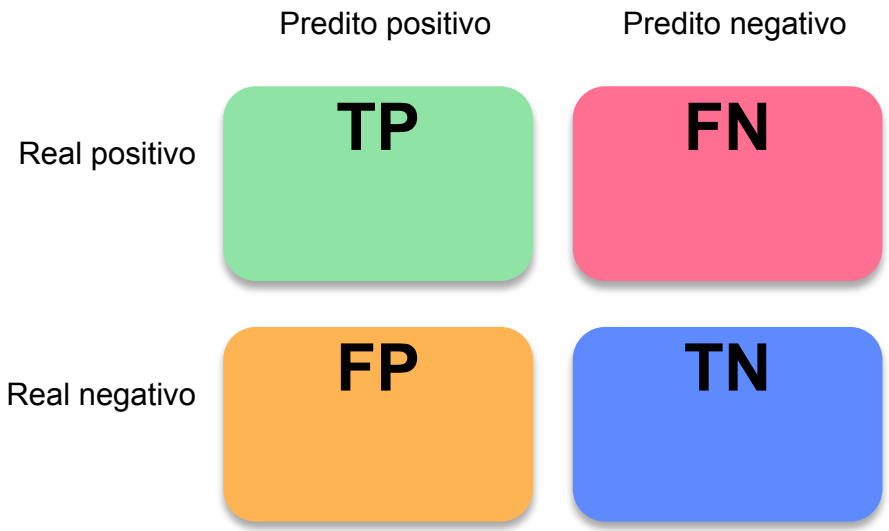


Bloco 03 — Processamento Sequencial

Métrica boa é métrica alinhada ao erro

Accuracy sozinha pode ocultar falhas graves — especialmente quando as classes são desbalanceadas.

MATRIZ DE CONFUSÃO



Precision = TP / (TP + FP)

Recall = TP / (TP + FN)

CLASSIFICAÇÃO

Precision, recall, F1, ROC-AUC; PR-AUC quando a classe positiva é rara.

REGRESSÃO

MAE é interpretável; RMSE penaliza erros grandes; examine resíduos.

SÉRIES TEMPORAIS

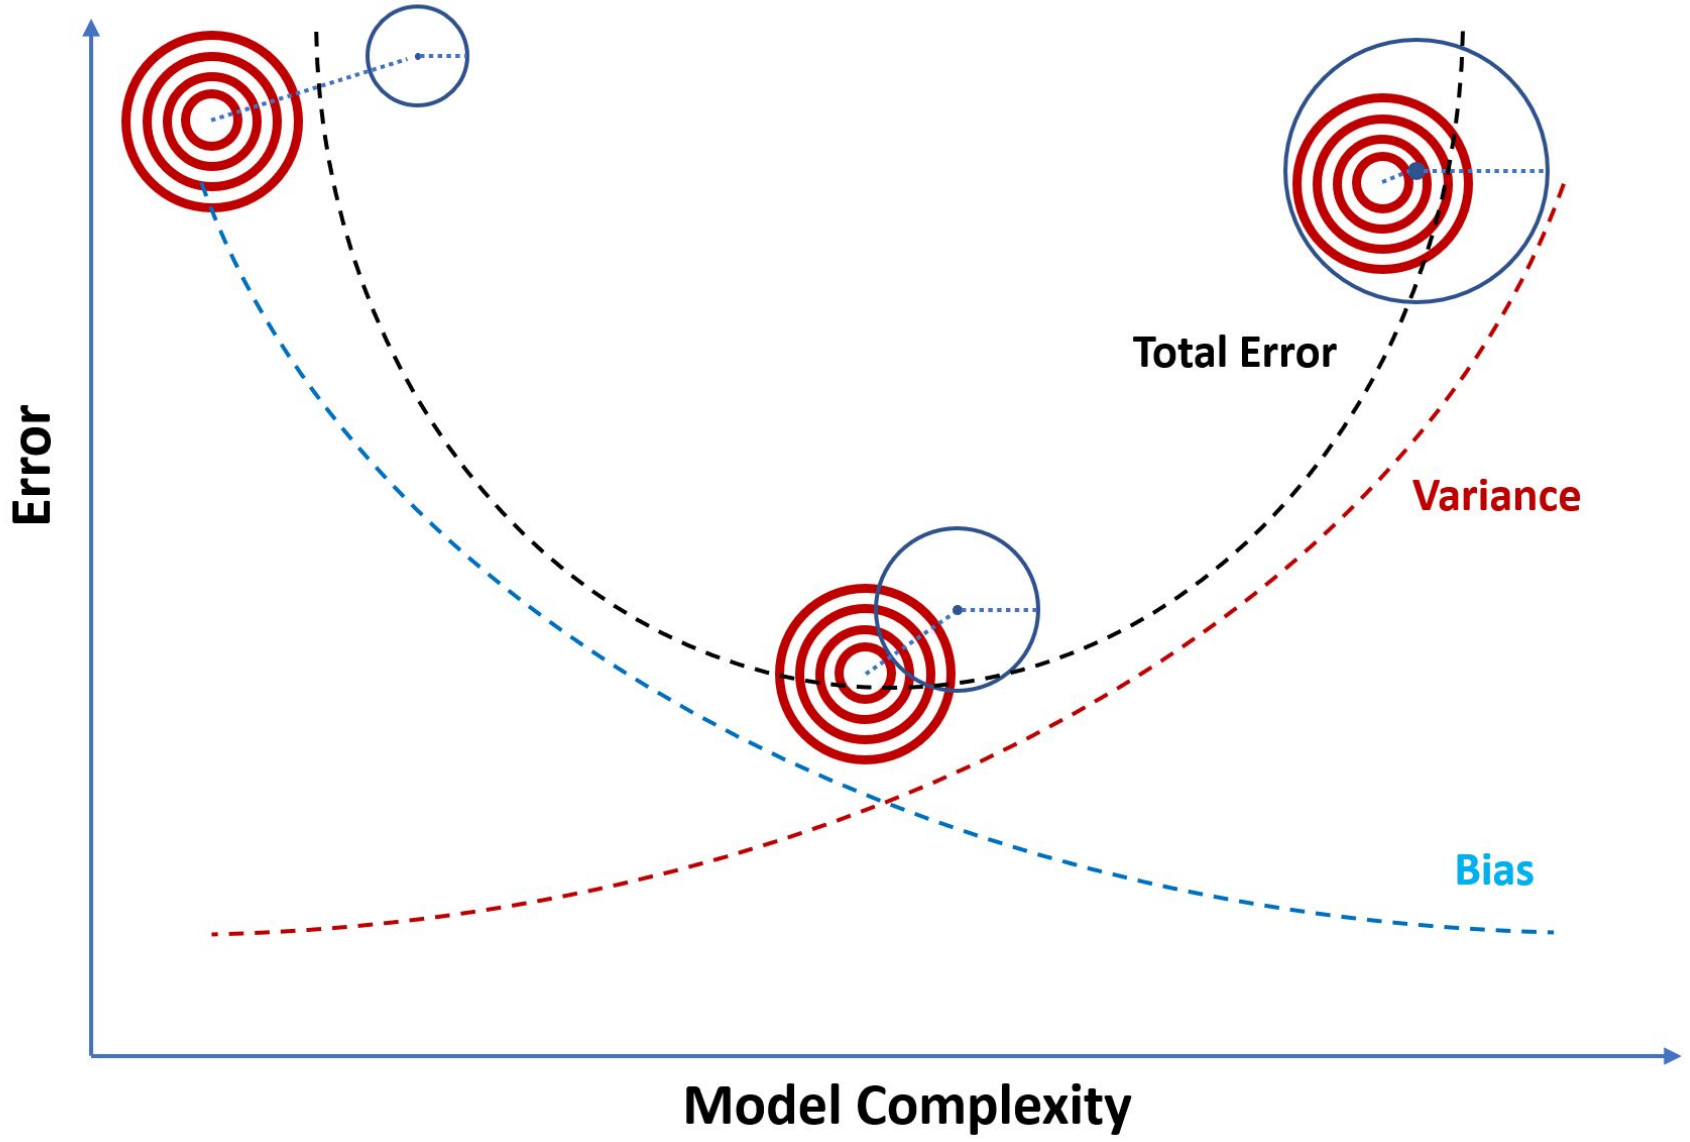
MAE/RMSE por horizonte e comparação com baselines ingênuos.

DECISÃO REAL

Inclua latência, custo, cobertura e impacto dos falsos positivos/negativos.

A pergunta não é “qual métrica é melhor?”, e sim “qual erro custa mais neste contexto?”

Bias-Variance Tradeoff



Regularização é controle de complexidade

L1 / L2

Penalizam magnitudes dos pesos; podem reduzir soluções excessivamente complexas.

Dropout

Desativa unidades aleatoriamente durante o treino; reduz coadaptação.

Early stopping

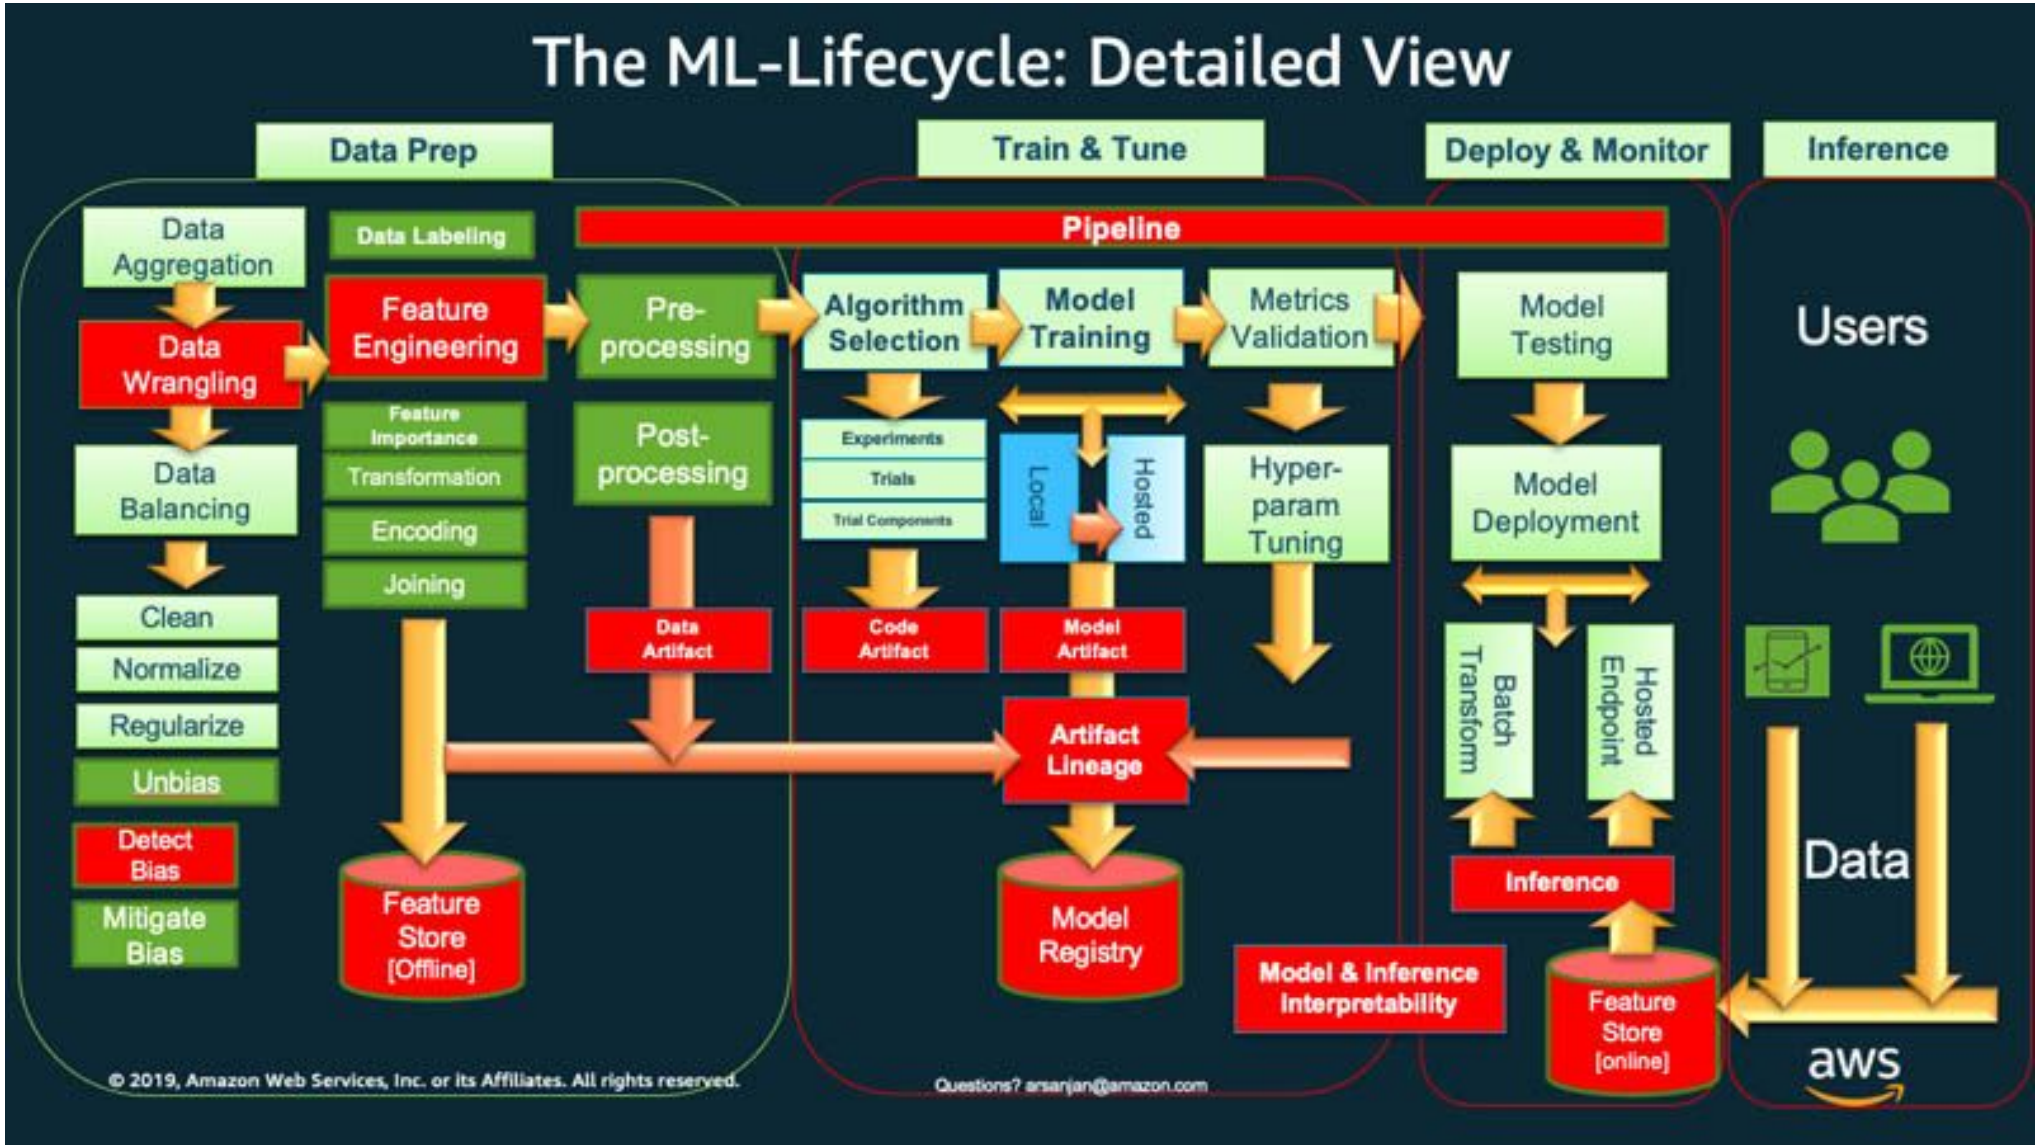
Interrompe quando a validação deixa de melhorar; restaura o melhor checkpoint.

Data augmentation

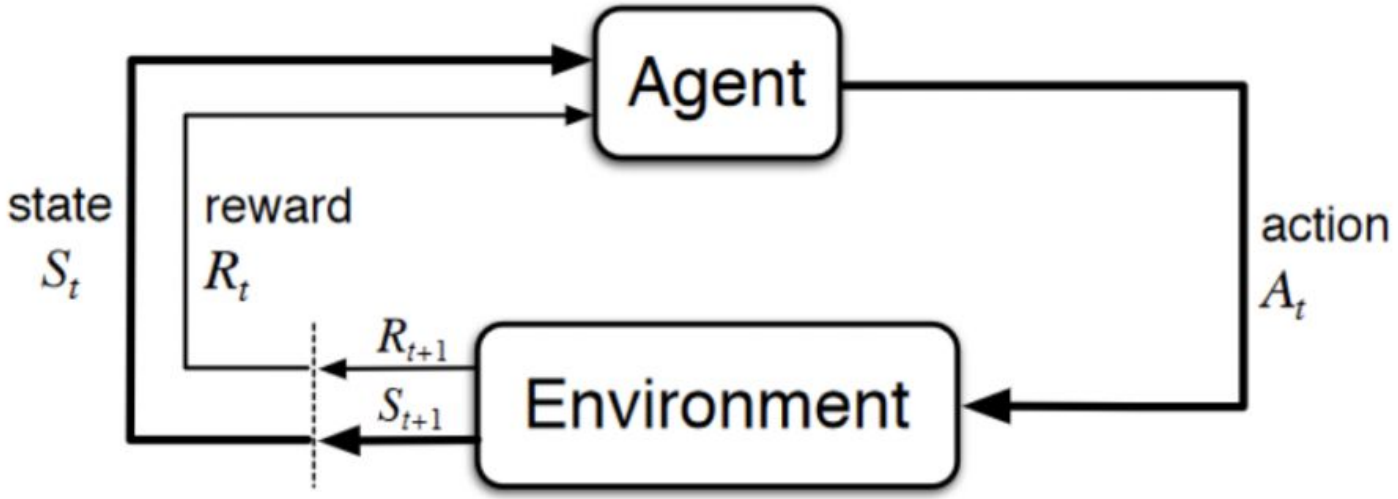
Cria variações plausíveis dos exemplos, sobretudo em visão computacional.

Diagnóstico → hipótese → intervenção → comparação controlada → registro do resultado

O ciclo de vida de um modelo



Aprendizado por reforço



O aprendizado por reforço é um paradigma de aprendizado de máquina em que um agente autônomo aprende a tomar decisões por meio de interações com um ambiente, buscando maximizar uma recompensa acumulada ao longo do tempo.

Síntese Paradigmática

Comparativo Entre Abordagens

Paradigma	Tipo de Dado Ideal	Método de Aprendizado	Casos de Uso Típicos
MLP	Dados Tabulares	Supervisionado (Gradient Descent)	Classificação/Regressão geral
CNN	Imagens, Matrizes 2D/3D	Filtros de Convolução	Reconhecimento Visual
RNN / LSTM	Séries Temporais, Texto	Recorrência Temporal	Previsão e Processamento de Linguagem
Computação evolutiva	Espaços de Busca Complexos	Busca Estocástica Evolutiva	Otimização e Seleção de Atributos

Conclusão

Considerações Finais

"Modelos de Aprendizado de Máquina e Algoritmos Genéticos são ferramentas de solução de problemas complexos — o sucesso reside no entendimento correto do espaço do problema."

Prof. Mateus Dalbone

Obrigado pelo Período!

Parabéns pelo empenho e dedicação ao longo do curso. Sucesso nas próximas etapas!

Dúvidas & Perguntas Finalizadoras

Image Sources



https://media.geeksforgeeks.org/wp-content/uploads/20251213151009129404/_neural_network.webp

Source: www.geeksforgeeks.org



https://media.geeksforgeeks.org/wp-content/uploads/20260217113409515144/working_of_cnn__.webp

Source: www.geeksforgeeks.org



https://colah.github.io/posts/2015-08-Understanding-LSTMs/img/RNN-unrolled.png

Source: colah.github.io



https://www.genetic-programming.com/BBB2028flowchartleft.gif

Source: www.genetic-programming.com